

Thu thập dữ liệu trò chơi điện tử trên nền tảng Steam và tiền xử lý cho bài toán xây dựng hệ thống gợi ý game dựa trên sở thích người dùng

Lê Thị Hà Phương

MSSV: 24521413

Khoa Khoa học và Kỹ thuật thông tin

Trường Đại học Công nghệ thông tin

- ĐHQG Thành phố Hồ Chí Minh

24521413@gm.uit.edu.vn

Nguyễn Bảo Quân

MSSV: 24521436

Khoa Khoa học và Kỹ thuật thông tin

Trường Đại học Công nghệ thông tin

- ĐHQG Thành phố Hồ Chí Minh

24521436@gm.uit.edu.vn

Tóm tắt nội dung—Nghiên cứu này trình bày một quy trình kỹ nghệ dữ liệu (Data Engineering) khép kín (End-to-End Pipeline) từ khâu thu thập tự động, tiền xử lý chuyên sâu đến khám phá (EDA) top 29.931 game phổ biến từ nền tảng Steam. Chúng tôi đã cô lập và xử lý thành công các lỗi hệ thống bao gồm dữ liệu khuyết thiếu ở thông số cấu hình phân cứng và dữ liệu trùng lặp logic do sai lệch phiên thời gian khi cào dữ liệu. Đặc biệt, để nâng cao chất lượng dữ liệu, thuật toán Bayesian Smoothing được triển khai nhằm bình ổn hiện tượng điểm cao ảo ở các sản phẩm ít tương tác, triệt tiêu thiên vị phổ biến (popularity bias). Cuối cùng, mô hình ngôn ngữ lớn Qwen-7B (lượng hóa 4-bit) được ứng dụng đột phá để ánh xạ hệ thống siêu dữ liệu nhãn (Tags) phức tạp về một cấu trúc phân loại đồng nhất. Bộ dữ liệu đầu ra đạt chuẩn hóa cao, thiết lập nền tảng dữ liệu sạch đáng tin cậy cho các bài toán phân tích quy mô lớn tiếp theo.

Index Terms—Kỹ nghệ dữ liệu (Data Engineering), Thu thập dữ liệu (Web Crawling), Tiền xử lý dữ liệu, Bayesian Smoothing, Mô hình ngôn ngữ lớn (LLM), Hệ thống khuyến nghị, Data Pipeline

I. GIỚI THIỆU

Trong kỷ nguyên số hóa và sự bùng nổ mạnh mẽ của ngành công nghiệp giải trí tương tác, Steam (thuộc tập đoàn Valve) hiện đang nắm giữ vị thế độc tôn với tư cách là nền tảng phân phối trò chơi điện tử trực tuyến lớn nhất thế giới. Quản lý danh mục lên đến hàng chục ngàn sản phẩm và phục vụ hàng triệu người dùng hoạt động đồng thời mỗi ngày, Steam đối mặt với bài toán tối ưu hóa trải nghiệm người dùng, tăng tỷ lệ giữ chân khách hàng thông qua việc cá nhân hóa danh mục sản phẩm. Do đó, nghiên cứu và phát triển các thuật toán khai phá dữ liệu hoặc hệ thống khuyến nghị (Recommendation Systems) đóng vai trò sống còn đối với nền tảng. Tuy nhiên, hiệu năng và độ chính xác của các mô hình toán học này phụ thuộc hoàn toàn vào tính toàn vẹn, độ sạch và độ tin cậy của bộ dữ liệu đầu vào, tuân theo nguyên lý kinh điển "Dữ liệu rác tạo ra kết quả rác" (Garbage In, Garbage Out).

Để có được nguồn tri thức phục vụ mô hình, việc tự động hóa trích xuất dữ liệu từ internet (Web Scraping / Data Crawling) là giai đoạn tiên quyết. Tuy nhiên, dữ liệu thô thu thập trực tiếp từ môi trường số luôn đối mặt với những thách thức nghiêm trọng về mặt cấu trúc và chất lượng. Bộ dữ liệu thô sau khi cào của

Steam chứa đựng nhiều điểm dị biệt hệ thống: tạp chất chuỗi văn bản ký tự đặc trưng vùng ở thuộc tính kinh tế (price), hiện tượng trùng lặp logic phân tán do sự chồng chéo của các phiên thời gian trong quá trình cào, và tỷ lệ khuyết thiếu rất cao ở các phân hệ cấu hình phân cứng do tính chất khai báo không đồng bộ của các nhà phát hành độc lập. Đặc biệt hơn, hệ thống nhãn phân loại (Tags) do cộng đồng tự phát gắn thẻ có độ đa dạng thực thể cực cao (high-cardinality) kèm theo nhiều ngôn ngữ và lỗi đồng nghĩa, trong khi các thuộc tính tương tác định lượng (PositiveReview, NegativeReview) lại tuân theo quy luật phân phối đuôi dài lệch phải cực đoan. Việc sử dụng các phương pháp tiền xử lý thủ công hoặc các bộ lọc heuristic thông thường không thể giải quyết triệt để các dạng nhiễu này, thậm chí làm bùng nổ số chiều của vector đặc trưng hoặc gây mất mát thông tin tương tác nghiêm trọng.

Để giải quyết các rào cản mang tính hệ thống trên, nghiên cứu này thiết lập và hiện thực hóa một quy trình kỹ nghệ dữ liệu đóng gói toàn diện (End-to-End Data Pipeline) trên tập dữ liệu gồm 29.931 mẫu thực tế được trích xuất từ Steam. Khác với các phương pháp tiếp cận truyền thống, nghiên cứu thiết kế một luồng xử lý dữ liệu tuần tự chặt chẽ, chia làm ba phân hệ chiến lược cốt lõi:

- Phân hệ Thu thập Dữ liệu (Data Crawling Pipeline): Thiết kế công cụ trích xuất hướng đối tượng tự động tương tác đồng thời với Steam API và bóc tách cấu trúc HTML từ Web Store. Hệ thống tích hợp cơ chế ghi đĩa trực tiếp và xử lý ngoại lệ (Exception Handling) nhằm đảm bảo khả năng chịu lỗi hệ thống, tối ưu hóa tốc độ cào dòng dữ liệu lớn và thu về tập dữ liệu thô ban đầu.
- Phân hệ Tiền xử lý cấu trúc và Chuẩn hóa ngữ nghĩa (Data Preprocessing Pipeline): Nhận đầu vào là tập dữ liệu thô từ phân hệ trước để thực hiện bóc tách, dọn dẹp vật lý, xử lý khuyết thiếu phân tầng và ép kiểu đồng bộ cho các trường số học dựa trên biểu thức chính quy (Regex). Đặc biệt, phân hệ tích hợp mô hình ngôn ngữ lớn chuyên biệt Qwen-7B (lượng hóa 4-bit) hoạt động như một hàm ánh xạ ngữ nghĩa thông minh, giải quyết triệt để bài toán bùng

nổ chiều không gian (Curse of Dimensionality) bằng cách đưa toàn bộ hệ thống nhãn cộng đồng lên về một bộ từ vựng mục tiêu nhất quán. Đầu ra của phân hệ này là một tập dữ liệu sạch cấu trúc (interim_dataset).

- Phân hệ Phân tích Khám phá và Kỹ nghệ Đặc trưng (EDA & Feature Engineering Pipeline): Sử dụng tập dữ liệu sạch để tiến hành khảo sát đa biến qua ma trận hệ số tương quan Pearson, phát hiện lỗi đa cộng tuyến và trực quan hóa xu hướng. Đồng thời, phân hệ triển khai phép biến đổi phi tuyến Log1p để ổn định phương sai cho phân phối đuôi dài, áp dụng toán học xác suất nghiệm trước Bayes (Bayesian Smoothing) để hiệu chỉnh đặc trưng chất lượng sản phẩm (Weighted Rating), triệt tiêu hoàn toàn hiện tượng điểm cao ảo của các mặt hàng thiếu bằng chứng tương tác (Small-sample Noise).

Về cơ bản, bài toán kỹ nghệ dữ liệu này được phát biểu thông qua hai trạng thái:

- Đầu vào: Nền tảng Steam Store trực tuyến chứa hàng ngàn thực thể trò chơi phi cấu trúc, phân mảnh thông tin phân cứng và hệ thống thẻ cộng đồng tự phát.
- Đầu ra: Bộ dữ liệu sạch, tối ưu hóa toán học, bảo toàn nguyên vẹn thứ bậc phân hóa đặc trưng và sẵn sàng nạp vào các mô hình khuyến nghị ở giai đoạn tiếp theo.

II. CÔNG TRÌNH LIÊN QUAN

A. Các nghiên cứu thế giới về xử lý thiên lệch dữ liệu tương tác (Interaction Bias)

Dữ liệu tương tác người dùng (User Ratings/Reviews) trên Steam thường bị chi phối nặng nề bởi quy luật Pareto (phần lớn lượt đánh giá tập trung vào các game bom tấn) và hiện tượng phương sai cực đoan ở các game ngách.

- Hướng tiếp cận lọc tính (Heuristic Thresholding): Các nghiên cứu truyền thống của Zuo và các cộng sự [1] hay Kim et al. [2] thường sử dụng giải pháp thô bạo là thiết lập một ngưỡng bộ lọc cứng (ví dụ: chỉ giữ lại các trò chơi có trên 50 hoặc 100 lượt đánh giá). Giới hạn của hướng này: Việc cắt bỏ cơ học này làm suy giảm nghiêm trọng lượng thông tin của các trò chơi thuộc vùng "đuôi dài" (Long-tail items), khiến hệ thống dữ liệu bị mất đi độ phong phú và gia tăng độ thưa thớt (sparsity) của ma trận.
- Hướng tiếp cận bình ổn hóa (Regularization): Để không phải xóa dữ liệu, các công trình nghiên cứu về hệ thống thương mại điện tử lớn của Amazon bởi Smith và các đồng nghiệp [3] đã ứng dụng các hàm phạt toán học để điều tiết điểm số. Kế thừa tư duy này, việc chúng tôi hiện thực hóa thuật toán Làm mượt Bayes (Bayesian Smoothing) với tham số phạt động cố định tại phân vị $Q_3(V)$ là một bước tiến giúp bảo toàn 100% dung lượng bản ghi (29.931 game) mà vẫn triệt tiêu được hiện tượng "điểm cao ảo" của các sản phẩm thiếu bằng chứng tương tác.

B. Các nghiên cứu thế giới về chuẩn hóa siêu dữ liệu phân loại đa nhãn (Multi-Label Metadata)

Hệ thống nhãn (Tags) do người dùng tự gắn trên Steam tạo ra một thách thức lớn về độ đa dạng thực thể cực đại (High Cardinality) và nhiễu ngữ nghĩa (Semantic Noise).

- Phương pháp mã hóa và so khớp truyền thống: Công trình của Silva et al. [4] áp dụng trực tiếp thuật toán mã hóa nhị phân đa nhãn (Multi-Label Binarization) lên toàn bộ các tag thu thập được. Hướng đi này bị cộng đồng khoa học quốc tế chỉ trích vì gây ra hiện tượng bùng nổ số chiều đặc trưng (Dimensionality Explosion), tạo ra ma trận thưa cực đoan làm mất đi độ tương phản khi tính toán khoảng cách tương đồng (Cosine Similarity). Nhằm khắc phục, Lee và các cộng sự [5] đã sử dụng khoảng cách chuỗi ký tự (như Levenshtein) hoặc xây dựng bộ từ điển đồng nghĩa (Synonym Dict) bằng luật cứng (Rule-based). Giới hạn của hướng này: Các bộ luật tĩnh hoàn toàn bất lực trước các nhãn mang tính ẩn dụ, viết tắt hoặc ngôn ngữ lóng thay đổi liên tục của cộng đồng game thủ.
- Xu hướng ứng dụng Mô hình ngôn ngữ lớn (LLM-based Processing): Trong các hội nghị khoa học gần đây (2024–2025), việc ứng dụng AI thể hệ mới để dọn dẹp dữ liệu đang trở thành một làn sóng đột phá. Nghiên cứu của Wang et al. [6] đã chứng minh các mô hình ngôn ngữ lớn có khả năng hiểu ngữ nghĩa vượt trội để gộp nhãn. Tuy nhiên, rào cản lớn nhất của họ là chi phí điện toán cao khi gọi API thương mại. Đề án của chúng tôi giải quyết triệt để bài toán này bằng một giải pháp hybrid: cô lập danh mục nhãn chuẩn bằng thống kê tần suất, sau đó chỉ nạp các nhãn hiếm vào mô hình nguồn mở Qwen-7B đã được lượng hóa 4-bit (4-bit quantization) tại chỗ. Phương pháp này vừa đảm bảo độ chính xác ngữ nghĩa ở mức cao nhất, vừa tối ưu hóa tài nguyên phần cứng, đạt chuẩn mực xử lý dữ liệu hiện đại của thế giới.

III. PHƯƠNG PHÁP NGHIÊN CỨU


Để chuyển hóa dữ liệu trò chơi trực tuyến thô thành bộ dữ liệu chuẩn hóa phục vụ bài toán khuyến nghị, nghiên cứu này xây dựng quy trình kỹ nghệ dữ liệu khép kín gồm ba giai đoạn tuần tự. Đầu tiên, Phân hệ thu thập dữ liệu đa mô-đun thực hiện quét danh mục để lấy mã định danh ứng dụng, đồng thời kết hợp gọi dữ liệu cấu trúc từ API và bóc tách cây mã nguồn HTML Store, tích hợp cơ chế lùi bước lũy tiến toán học và ghi đĩa trực tiếp để kháng lỗi hệ thống. Tiếp theo, dữ liệu thô được chuyển giao sang Phân hệ thiết kế đặc trưng toán học nhằm cô lập các biến khuyết thiếu cấu hình, xử lý trùng lặp logic và áp dụng thuật toán Làm mượt Bayes (Bayesian Smoothing) để bình ổn dải điểm số tương tác. Cuối cùng, Phân hệ tiền xử lý sâu tiến hành đồng bộ định dạng vật lý và ứng dụng mô hình ngôn ngữ lớn Qwen-7B (lượng hóa 4-bit) để suy luận ngữ nghĩa, giải quyết triệt để sự bùng nổ số chiều của hệ thống nhãn mở có độ đa dạng thực thể cực đại.

A. Phân hệ thu thập dữ liệu hướng đối tượng đa mô-đun (Hệ thống SteamCrawler)

Hành trình dịch chuyển của dữ liệu được bắt đầu bằng việc thiết lập một hạ tầng thu thập tự động trên quy mô lớn, đóng gói đồng bộ trong thư mục SteamCrawler. Để giải quyết bài toán phân mảnh thông tin từ nền tảng Steam Store—nơi không một đường dẫn API đơn lẻ nào cung cấp trọn vẹn thuộc tính nội dung, cấu hình hệ thống lẫn định lượng tương tác người

dùng—phân hệ được thiết kế theo kiến trúc hướng đối tượng và phân rã thành bốn giai đoạn thực thi tuần tự của một đường ống kỹ nghệ dữ liệu (Data Pipeline). Luồng vận hành tổng thể phối hợp đồng bộ giữa việc khai thác dữ liệu có cấu trúc từ API và bóc tách cây mã nguồn HTML Store phi cấu trúc, được điều khiển tập trung bởi lớp trung tâm SteamCrawler trong mô-đun Crawler.py.

Kiến trúc tổng quan và đường đi của dòng chảy dữ liệu qua các giai đoạn trong phân hệ được mô tả chi tiết trong Hình 3.1 dưới đây:



Hình 1. Sơ đồ Data Pipeline bốn giai đoạn của phân hệ SteamCrawler.

1) Quản lý cấu hình phiên và cơ chế kháng lỗi hệ thống động (Config.py, Client.py)

Mọi ranh giới vận hành của đường ống dữ liệu được định nghĩa tập trung trong lớp dữ liệu Config. Lớp này thiết lập các tham số điều hướng luồng bao gồm định danh khu vực (cc="us"), ngôn ngữ truy vấn (lang="english"), quy mô dữ liệu mục tiêu (pages=600, per_page=50), và các giới hạn kỹ thuật như thời gian ngắt kết nối (timeout_seconds=25).

Để thực thi các yêu cầu mạng một cách tối ưu, lớp Client được xây dựng như một tầng trừu tượng bao bọc thư viện requests, khởi tạo một phiên làm việc duy nhất (requests.Session()). Cơ chế này kích hoạt kỹ thuật tối ưu hóa kết nối (Connection Pooling), tái sử dụng các kết nối TCP hiện có để giảm thiểu độ trễ bắt tay mạng. Thách thức lớn nhất khi tương tác với hạ tầng Steam là rủi ro máy chủ từ chối phản hồi do vượt ngưỡng tần suất yêu cầu cho phép, trả về mã lỗi HTTP Status Code 429 (Too Many Requests) hoặc lỗi hệ thống 503. Để bảo vệ hệ thống khỏi nguy cơ đứt gãy tiến trình, tại hàm get() của mô-đun Client, một Cơ chế Lùi bước Lũy tiến kháng chặn Tần suất (Exponential Backoff Policy) được triển khai thông qua vòng lặp thử lại tối đa (max_retries=10). Khi bắt được ngoại lệ mạng hoặc mã lỗi hệ thống, thời gian tạm dừng dòng chảy dữ liệu được tính toán tăng dần theo hàm mũ của số lần thất bại:

$$\text{backoff} = \text{sleep_seconds} \times 5^{\text{attempt}}$$

Giải pháp này giúp hệ thống tự động giảm áp lực truy cập lên hạ tầng Steam, bảo vệ địa chỉ IP khỏi các cơ chế chặn tường lửa (Rate-Limiting Mitigation) mà không cần can thiệp thủ công.

2) Các giai đoạn thực thi cốt lõi của đường ống dữ liệu (Pipeline Stages)

Dựa trên kiến trúc tổng quan ở Hình 3.1, dòng chảy dữ liệu bên trong hệ thống SteamCrawler được thực hiện thông qua 4 giai đoạn logic nối tiếp:

- **Giai đoạn 1: Định danh Thực thể & Quét Chỉ mục (Index Scanning & Ingestion):** Lớp SearchService trong tệp Search.py gửi truy vấn tuần tự đến dịch vụ tìm kiếm của Steam Store thông qua hàm FetchPage(). Kết quả cấu trúc HTML trả về (results_html) được nạp vào bộ phân tích cú pháp cây DOM của thư viện BeautifulSoup4. Tại đây, hàm ParseAppid() áp dụng phương pháp khớp mẫu chuỗi (Pattern Matching) bằng biểu thức chính quy `re.search(r"/app/(\d+)/", url)`. Thuật toán sẽ quét toàn bộ các đường dẫn (URL) tìm được, định vị vùng chữ cố định /app/ và dùng toán tử `\d+` để trích xuất chuỗi ký số có độ dài bất định đại diện cho mã định danh duy nhất của trò chơi. Nhờ cơ chế nhóm bắt giữ (Capture Group) của cặp ngoặc đơn `()`, hệ thống loại bỏ hoàn toàn các ký tự thừa từ liên kết gốc, lấy ra mã AppID chính xác để làm khóa chính điều hướng cho các giai đoạn sau.
- **Giai đoạn 2: Kiểm định Trạng thái & Loại trùng Logic (State Verification & Deduplication):** Để đảm bảo tính bất biến (idempotence) và kháng đổ vỡ tiến trình (Fault-tolerant Resume), mô-đun Saving.py triển khai hàm CheckAppid(). Hàm này tiến hành quét tệp kết quả CSV hiện tại ngay khi khởi động hệ thống để trích xuất tập hợp các mã định danh đã được thu thập hoàn tất từ trước (CrawledID). Bằng việc thực hiện phép lọc loại trừ giữa danh sách tổng và danh sách đã cào, hệ thống có khả năng phục hồi trạng thái làm việc với độ phức tạp $O(1)$. Nếu xảy ra sự cố ngắt kết nối đột ngột, ở phiên chạy kế tiếp, hệ thống tự động bỏ qua các mục trùng lặp mà không thực hiện lại các yêu cầu HTTP, giúp tối ưu hóa tài nguyên mạng và thời gian thực thi.
- **Giai đoạn 3: Trích xuất Đa tầng & Hợp nhất Siêu dữ liệu (Multi-source Metadata Extraction):** Đối với danh sách mục tiêu đã qua bộ lọc trùng, hệ thống kích hoạt vòng lặp đối tượng (sử dụng thư viện tqdm để trực quan hóa tiến độ) và thực hiện bóc tách tri thức từ hai nguồn độc lập:
 - Khai thác dữ liệu có cấu trúc qua Web API Endpoint: Lớp AppDetails (appDetails.py) gọi API chính thức để lấy cấu trúc JSON dữ liệu gốc. Hàm Extract() (Extractor.py) thực hiện bóc tách các trường cơ bản như tên trò chơi, thể loại (Genres), nhà phát triển, nhà xuất bản và ngày phát hành. Riêng thuộc tính giá (price_overview) được chuẩn hóa về dạng số thực tiền tệ. Đối với trường mô tả chi tiết chứa tạp chất mã hiển thị, mô-đun htmlCleaner.py sử dụng thư viện BeautifulSoup và biểu thức chính quy để loại bỏ hoàn toàn các thẻ định dạng, trả về văn bản thuần túy ngữ nghĩa (Text Sanitization).
 - Bóc tách DOM từ cú pháp cây HTML Store: Nhằm thu thập các siêu dữ liệu không hỗ trợ qua API, hệ thống gửi yêu cầu lấy mã nguồn trang cửa hàng để

phân tích HTML phi cấu trúc. Hàm ParseReview() (ReviewParser.py) giải cấu trúc thực thể JSON từ endpoint đánh giá để cô lập ba chỉ số tương tác: hạng mục điểm số, số lượng đánh giá tích cực và tiêu cực. Song song đó, hàm ParseSysReq() (SystemParser.py) định vị khối cấu trúc hệ thống, duyệt qua các phần tử danh sách để tách chuỗi cấu trúc phần cứng thành ba thuộc tính độc lập: hệ điều hành, dung lượng bộ nhớ RAM và bộ vi xử lý yêu cầu. Cuối cùng, hàm ParseTag() (tagParser.py) cô lập vùng chứa thẻ cộng đồng (glance_tags), trích xuất chuỗi nhãn văn bản và loại bỏ các phần tử trùng lặp trước khi gộp thành chuỗi ngăn cách bằng dấu phẩy.

- Giai đoạn 4: Cấu trúc hóa Bản ghi & Ghi đĩa Trực tiếp (Record Structuring & Persistent Storage): Toàn bộ các trường thông tin bóc tách từ API và Store HTML được lớp điều khiển tập hợp thành một cấu trúc dòng từ điển (row) đồng nhất. Thay vì lưu trữ trên bộ nhớ đệm RAM gây rủi ro tràn dung lượng vật lý khi xử lý dữ liệu lớn, hàm AppendCSV() (Saving.py) thực hiện cơ chế ghi lũy kế trực tiếp xuống ổ đĩa cứng ngay khi kết thúc mỗi vòng lặp của thực thể trò chơi. Cơ chế này vừa giải phóng tài nguyên bộ nhớ liên tục, vừa bảo toàn dữ liệu tuyệt đối trước các sự cố sập nguồn đột ngột, kết tinh thành công tập dữ liệu thô gồm 29.931 dòng bản ghi bền vững.

B. Phân hệ tiền xử lý và chuẩn hoá dữ liệu chuyên sâu

Sau giai đoạn thu thập dữ liệu thô (Raw Data) từ hạ tầng cào dữ liệu trực tuyến, tập dữ liệu thu về bao gồm 29.931 bản ghi chứa nhiều tạp chất chuỗi, lỗi khuyết thiếu phân tán và sự hỗn loạn về mặt ngữ nghĩa của hệ thống thẻ. Phân hệ tiền hành thiết lập một đường ống tiền xử lý dữ liệu khép kín (Data Preprocessing Pipeline) gồm hai giai đoạn cốt lõi: Làm sạch kết hợp Điền khuyết cấu trúc (Cleaning & Imputation) và Chuẩn dữ liệu nâng cao dựa trên Mô hình Ngôn ngữ lớn (Advanced Normalization & LLM Tag Mapping).

1) Phân hệ Làm sạch và Điền khuyết cấu trúc (Cleaning & Imputation Pipeline)

Mục tiêu của giai đoạn này là đồng bộ hóa kiểu dữ liệu vật lý và áp dụng các chiến lược can thiệp phân tầng để xử lý các giá trị khuyết thiếu (NaN) dựa trên đặc tính của từng nhóm thuộc tính:

- Xử lý Trùng lặp và Đánh lại Thứ hạng Hệ thống (Rank Realignment): Do đặc thù cào dữ liệu trực tuyến theo đợt ngắt quãng (tránh bị hệ thống Steam chặn IP), tập dữ liệu thô xuất hiện hiện tượng trùng gổ đầu logic và phân mảnh thứ hạng. Kết quả khảo sát ghi nhận nhiều bản ghi khác nhau nhưng cùng chia sẻ giá trị Rank = 1. Để gỡ nhiễu xếp hạng, phân hệ cô lập các bản ghi tranh chấp, giữ nguyên thứ tự sắp xếp tuyến tính ban đầu (phản ánh xu hướng phổ biến tương đối), sau đó áp dụng phép toán tạo mảng số nguyên liên tục:

$$NewRank = np.arange(1, \mathcal{N} + 1)$$

Thao tác này ép toàn bộ dải dữ liệu tuân theo phân phối cấp số cộng đơn trị từ 1 đến hết, loại bỏ hoàn toàn lỗi trùng lặp thứ hạng.

- Xử lý khuyết thiếu thuộc tính Thời gian (ReleaseDate): Ghi nhận số lượng khuyết thiếu không đáng kể (14 mẫu). Vì ngày phát hành là thông tin định danh niên giám cốt lõi, mọi phép suy đoán toán học đều gây sai lệch thông tin thực tế. Phân hệ áp dụng lệnh loại bỏ vật lý cố định: `df.dropna(subset=['ReleaseDate'], inplace=True)`.
- Cơ chế Điền khuyết Đối chiếu Chéo (Developers & Publishers): Nhận thấy mối ràng buộc thực tế giữa nhà phát triển và nhà phát hành trên Steam Store, phân hệ triển khai cơ chế Điền khuyết đối chiếu chéo (Cross-column Fallback): lấy dữ liệu cột Developers lấp sang cho Publishers bị thiếu và ngược lại. Những trường hợp cực đoan thiếu cả hai thông tin nguồn gốc này sẽ bị loại bỏ để đảm bảo chất lượng cho hệ gợi ý.
- Xử lý thuộc tính Văn bản mô tả (Description): Để bảo toàn quy mô mẫu, các trường văn bản trống được thay thế bằng chuỗi ký tự tiêu chuẩn "No description", ngăn chặn các lỗi ngắt quãng chuỗi (Attribute Error) khi xử lý ngôn ngữ tự nhiên về sau.
- Xử lý các Yêu cầu Cấu trúc Vật lý (OsRequirement, MemoryRequirement, CpuRequirement): Các trường thông tin cấu trúc phần cứng gặp tỷ lệ khuyết thiếu rất cao (từ 2.900 đến gần 4.000 mẫu). Dưới góc độ vận hành, thuộc tính phần cứng bị trống đồng nghĩa với việc trò chơi đó không có đòi hỏi khắt khe về mặt thiết bị. Hệ thống gán nhãn đồng bộ bằng chuỗi "No requirement" để chuẩn bị cấu trúc cho bộ lọc biểu thức chính quy (Regex) ở giai đoạn sau.
- Ràng buộc nội dung giữa Thể loại và Thẻ (Genres & Tags): Hệ thống thẻ cộng đồng (Tags) bị khuyết thiếu 1.614 mẫu. Phân hệ thiết lập cơ chế Fallback nội dung: nếu Genres thiếu sẽ được đưa về chuỗi rỗng, sau đó nếu cột Tags bị rỗng, hệ thống tự động lấy thông tin từ cột Genres lấp sang để bảo toàn tối đa tri thức phân loại nội dung.

Sau khi kết thúc Giai đoạn 1, hệ thống thực hiện kiểm định tổng quát thông qua `df.isnull().sum()` để đảm bảo ma trận dữ liệu đạt trạng thái sạch hoàn toàn (0 giá trị khuyết thiếu) và xuất ra tệp dữ liệu trung gian `data.csv`.

2) Chuẩn hóa dữ liệu nâng cao dựa trên Mô hình Ngôn ngữ lớn (Advanced Normalization & LLM Tag Mapping)

Nạp tệp dữ liệu trung gian sạch cấu trúc vào phân hệ nâng cao, hệ thống tiến hành bóc tách sâu các chuỗi văn bản phức hợp để kỹ nghệ đặc trưng và chuẩn hóa ngữ nghĩa hệ thống thẻ:

- Định lượng hóa thuộc tính kinh tế (price): Phân hệ triển khai bộ lọc chuỗi để loại bỏ hoàn toàn ký tự vùng ("\$\$"), đồng thời thực hiện ánh xạ logic chuyển đổi các nhãn định tính của game miễn phí (như "Free", "Free To Play") về giá trị số thực 0.0, phục vụ cho các thuật toán tính khoảng cách ma trận.
- Trích xuất thông số cấu trúc phần cứng bằng Biểu thức chính quy (Regex Parsing): Áp dụng bộ lọc biểu thức chính quy (Regular Expressions) để cô lập và trích xuất chỉ số vật lý định lượng từ các khối văn bản thô. Đối với

MemoryRequirement (RAM), hệ thống tách lọc con số dung lượng và đồng bộ về đơn vị Gigabyte (GB) dưới dạng số thực. Đối với CpuRequirement (CPU), các thông tin lõi (Xung nhịp GHz, dòng chip) được bóc tách để phân đoạn cấu hình thiết bị.

- Chuẩn hóa ngữ nghĩa hệ thống thẻ bằng Mô hình Qwen 7B: Hệ thống thẻ cộng đồng (Tags) chứa hàng ngàn nhãn tự phát, gây ra hiện tượng dữ liệu cực thưa (Data Sparsity) và bùng nổ số chiều (Curse of Dimensionality). Để giải quyết, phân hệ ứng dụng mô hình ngôn ngữ lớn Qwen 7B (Quantized 4-bit) làm bộ ánh xạ tri thức thông minh:
 - Cơ chế Prompt Engineering: Cấu trúc câu lệnh truy vấn nghiêm ngặt để ép mô hình Qwen 7B phân tích ngữ nghĩa sâu và bắt buộc phải ánh xạ các tag hiếm/nhiều về một nhãn chuẩn tương đương gần nhất trong Bộ từ vựng mục tiêu (Target Vocabulary) đã thiết lập sẵn.
 - Lượng hóa 4-bit (4-bit Quantization): Nén cấu trúc mô hình về định dạng int4 giúp giảm dung lượng VRAM tiêu thụ xuống mức tối thiểu, tối ưu hóa tốc độ xử lý batch quy mô lớn trên hạ tầng phần cứng giới hạn.
 - Hạ tầng kiểm định vòng lặp (Validation Loop): Kết xuất tự động tập mẫu đối sánh [raw_tag, mapped_tag] ra tệp validation_sample.csv phục vụ quy trình hậu kiểm soát chất lượng từ con người (Human-in-the-loop), bảo đảm tính chính xác tuyệt đối trước khi đóng gói dữ liệu đầu ra hoàn chỉnh (interim_dataset).

C. Phân hệ thiết kế đặc trưng toán học và phân tích dữ liệu khám phá (EDA)

Sau khi tập dữ liệu thô từ quá trình cào dữ liệu trực tuyến được dọn dẹp vật lý và chuẩn hóa ngữ nghĩa, hệ thống thu về một kho trạng thái trung gian ổn định. Tuy nhiên, để các thuật toán khuyến nghị (Recommendation Systems) có thể vận hành chính xác, dữ liệu cần phải trải qua giai đoạn Phân tích Khám phá Dữ liệu (EDA) và Kỹ nghệ Đặc trưng (Feature Engineering). Đây không đơn thuần là các thao tác thống kê cơ học, mà là hành trình "khai quật" các quy luật thị trường ẩn giấu, cấu trúc lại các biến số định lượng lệch cực đoan và số hóa không gian ngữ nghĩa văn bản thành các vector toán học tối ưu.

1) Khảo sát Biến động Quy mô và Kiểm định Ma trận Khuyết thiếu (Data Quality Check)

Tiến trình phân tích khởi đầu bằng một phép thử đối sánh toàn diện nhằm đo lường sự thay đổi của không gian mẫu trước và sau khi đi qua đường ống tiền xử lý

- Sự cô đọng của không gian dòng (Sample Space Realignment): Tập dữ liệu thô ban đầu (df_raw) ghi nhận tổng cộng 29.931 bản ghi. Qua bộ lọc loại bỏ các bản ghi trùng lặp logic xếp hạng và đứt gãy thông tin lịch sử, tập dữ liệu sạch (df_clean) được cô đọng lại còn 29.630 dòng. Việc loại bỏ 301 dòng nhiễu hệ thống (chiếm tỷ lệ 1.0%) giúp bảo toàn tối đa kích thước mẫu lớn nhưng triệt tiêu hoàn toàn nguy cơ thiên lệch phân phối.
- Mở rộng không gian thuộc tính (Feature Space Expansion): Số lượng chiều tính năng (Cột) được nâng cấp

từ 18 cột (ở file thô) lên thành 19 cột ở file sạch. Sự gia tăng này đánh dấu việc bóc tách thành công các biến cấu hình phần cứng vì xử lý tự do thành các đặc trưng số thực độc lập bao gồm dung lượng xung nhịp CPU_GHz, mức độ phân tầng thiết bị CPU_tier, và chỉ số định danh CPU_req.

- Bản đồ mật độ khuyết thiếu trước và sau xử lý: Thống kê chi tiết chứng minh toàn bộ các trường dữ liệu từng bị khuyết thiếu nặng nề ở file thô (như bộ nhớ động MemoryRequirement khuyết 13.31%, vì xử lý CpuRequirement khuyết 12.89%, hệ điều hành OsRequirement khuyết 9.81%, và thẻ cộng đồng Tags khuyết 5.39%) đã được kéo giảm hoàn toàn về mức 0.0% tỷ lệ khuyết thiếu trên không gian mẫu mới. Ma trận dữ liệu đã chuyển dịch từ cấu trúc thưa gãy sang trạng thái đặc (Dense Matrix), loại bỏ hoàn toàn rủi ro gây ngắt quãng luồng tính toán đại số tuyến tính của mô hình gợi ý.


2) Khám phá Phân phối Đặc trưng Định lượng và Chiến lược Ổn định phương sai

Bước tiếp theo của tiến trình tập trung phân tích hình học phân phối mật độ của ba biến số độc lập mang tính cốt lõi: giá tiền (price) cùng hệ thống lượng hóa tương tác (PositiveReview và NegativeReview).

- Nghịch lý Đuôi dài và Phân phối Lệch phải Cực đoan (Extreme Right-Skew): Khi tiến hành vẽ biểu đồ mật độ phân phối, hệ thống ghi nhận một hiện tượng bất thường hình học: cả ba biến số đều tuân theo quy luật Pareto (Quy luật 80/20) cực đoan. Phần lớn các trò chơi độc lập (Indie Games) tập trung ở phân khúc giá thấp hoặc miễn phí (0.0) và có lượng tương tác review vô cùng thưa thớt. Ngược lại, một nhóm rất nhỏ các trò chơi bom tấn (AAA) lại chiếm giữ các mốc giá cao kỷ lục và kích hoạt lượng đánh giá khổng lồ lên đến hàng triệu lượt. Sự chênh lệch biên độ này tạo ra một dải phân phối kéo dài bất tận về phía bên phải (Right-Skewed / Long-tail distribution). Nếu đưa trực tiếp các con số thô này vào hàm khoảng cách (như Cosine Similarity), các siêu phẩm đại chúng sẽ lấn át hoàn toàn các chiều dữ liệu khác, làm sập năng lực cá nhân hóa của hệ gợi ý.
- Giải pháp Biến đổi Phi tuyến Logarithm (Log Transformation): Để giải quyết triệt để sự mất cân bằng này, phân hệ kích hoạt phép biến đổi phi tuyến cơ số 10:

$$\tilde{x} = \log_{10}(x + 1)$$


Việc cộng thêm 1 đóng vai trò kỹ thuật quan trọng nhằm bảo toàn tính hợp lệ toán học tại các điểm gốc tọa độ bằng 0 (game miễn phí hoặc chưa có lượt review). Kết quả thực nghiệm cho thấy, phép biến đổi Log1p hoạt động như một bộ nén lò xo: nó kéo các giá trị ngoại lai cực đại (Outliers) lại gần tâm và trải phẳng các cột tần suất thưa thớt. Phân phối đuôi dài lập tức được co gọn và tiệm cận về dạng phân phối chuẩn (Normal Distribution), giúp ổn định phương sai hệ thống.



Hình 2. Biểu đồ đối sánh phân phối mật độ của biến định lượng trước và sau khi áp dụng Log Transformation.

3) Phân tích Tương quan Đa biến và Hiện tượng Đa cộng tuyến (Multivariate Correlation)

Sau khi đưa các biến số về dải phân phối mượt bằng Log1p, phân hệ tiến hành thực hiện các phép thử thống kê đa biến nhằm khám phá mối quan hệ tuyến tính nội tại giữa các đặc trưng số. Công cụ cốt lõi được sử dụng là Hệ số tương quan mô-men tích Pearson (Pearson Correlation Coefficient). Kết quả tính toán ma trận được trực quan hóa toàn diện thông qua biểu đồ nhiệt (Correlation Heatmap) dưới đây:



Hình 3. Ma trận hệ số tương quan Pearson giữa các thuộc tính định lượng sau khi ổn định phương sai.

Từ cấu trúc định lượng hiển thị trên biểu đồ nhiệt, hệ thống bóc tách được hai quy luật phân hóa dữ liệu mang tính bản chất:

- Sự đồng thuận cực mạnh giữa các biến tương tác (Hiện tượng Đa cộng tuyến): Cặp biến tương tác LogPositiveReview và LogNegativeReview thể hiện một hệ số tương quan dương vô cùng lớn (tiệm cận ngưỡng từ 0.85 đến 0.95). Quy luật này phản ánh thực tế thương mại trên Steam Store: Một trò chơi càng thu hút được nhiều sự chú ý (độ phổ biến cao) thì đồng thời cả lượng đánh giá tốt lẫn lượng đánh giá xấu đều tăng trưởng tỷ lệ thuận với nhau. Hiện tượng này đặt ra bài toán về Đa cộng tuyến (Multicollinearity). Nếu mô hình gợi ý sử dụng song song


cả hai thuộc tính độc lập này, chúng sẽ làm phóng đại sai lệch do trùng lặp thông tin (Data Redundancy). Đây chính là luận cứ khoa học thúc đẩy nghiên cứu phải kỹ nghệ ra một biến tổng hợp duy nhất đại diện cho chất lượng sản phẩm (biến Weighted Rating ở bước Bayes sau).

- Sự độc lập độc trị của thuộc tính chi phí (LogPrice): Trái ngược với nhóm tương tác, thuộc tính giá cả (LogPrice) thể hiện hệ số tương quan rất thấp (gần như tiệm cận về mức tuyến tính yếu 0.0) khi đặt cạnh các biến số về lượt review. Tri thức bóc tách chỉ ra rằng giá tiền của một trò chơi không hề quyết định mức độ tương tác hay tỷ lệ phản hồi của cộng đồng. Các tựa game miễn phí vẫn có thể kích hoạt lượng tương tác khổng lồ và ngược lại. Do đó, trong kiến trúc của hệ gợi ý lai, LogPrice sẽ đóng vai trò là một chiều đặc trưng độc lập (Orthogonal Feature), phục vụ riêng cho các bộ lọc ràng buộc kinh tế thay vì phân nhóm chất lượng nội dung.

Đo lường và trực quan hoá tính hoàn chỉnh (Completeness Check): Tính hoàn chỉnh được định nghĩa là trạng thái không còn sự tồn tại của các giá trị khuyết thiếu (NaN / Null) tại tất cả các thuộc tính trong không gian mẫu

- Cô lập và điền khuyết giá trị trống (Missing Values Mitigation):

Hệ thống thực hiện quét diện rộng thông qua các hàm thống kê lỗi khuyết thiếu toán học để cô lập danh sách các thuộc tính trống (NaN).



Hình 4. Biểu đồ tỷ lệ dữ liệu khuyết thiếu của các thuộc tính hệ thống.

Kết quả ghi nhận dữ liệu bị khuyết thiếu chia làm hai nhóm rõ rệt:


- Nhóm cấu hình phần cứng (MemoryRequirement, CpuRequirement, OsRequirement): Có tỷ lệ khuyết thiếu rất cao (đặc biệt là ở các tựa game cũ hoặc game cấu hình siêu nhẹ không yêu cầu thông số khắt khe). Việc xử lý nhóm này đòi hỏi sự cẩn trọng cao vì đây là các thuộc tính ràng buộc vật lý, hệ thống quyết định bảo toàn các giá trị trống hoặc gán nhãn hệ thống để chuyển dịch sang phân đoạn phân tích sâu ở bước sau, thay vì áp dụng các kỹ thuật điền khuyết toán học làm sai lệch yêu cầu phần cứng thực tế của trò chơi.
- Nhóm dữ liệu nội dung (Genres, Developers, Publishers, Tags): Xuất hiện tỷ lệ trống do một số trò chơi độc lập (Indie) chưa cập nhật đầy đủ thông

tin trên Steam Store. Nhằm tránh tổn thất tri thức nội dung và giữ nguyên quy mô mẫu cho hệ gợi ý, phương pháp Điền khuyết thực thể tĩnh (Static Imputation) được áp dụng để thay thế các giá trị NaN bằng chuỗi tương minh "Unknown".

- Xử lý bản ghi trùng lặp (Deduplication):

Đây là bước chốt chặn đầu tiên của quy trình làm sạch dữ liệu. Bộ dữ liệu thô ban đầu được chạy hàm kiểm tra trùng lặp trên toàn bộ các thuộc tính hệ thống và trả về kết quả bằng 0, chứng tỏ dữ liệu sau khi cào đã tránh được hiện tượng trùng lặp hàng ở mức hệ thống. Tuy nhiên, để đảm bảo tính toàn vẹn dữ liệu ở mức nghiệp vụ, phân hệ tiếp tục thực hiện rà soát chuyên sâu dựa trên mã định danh trò chơi.

Do đặc thù thuật toán phân trang của Steam Store thường ưu tiên đẩy các tựa game phổ biến lên đầu danh sách ở các phiên truy vấn khác nhau, tập dữ liệu thô đã gặp phải hiện tượng gổ đầu chỉ mục. Kết quả rà soát thực nghiệm được thể hiện rõ trong Hình 3.



Hình 5. Đánh giá hiện tượng trùng lặp đối với nhóm trò chơi có độ phổ biến cao.

Kết quả cho thấy nhiều trò chơi khác nhau cùng xuất hiện ở một vị trí ranking. Điều này xảy ra do dữ liệu được thu thập qua nhiều phiên crawling khác nhau khi hệ thống bị giới hạn bởi cơ chế chống scraping của Steam.

Hiện tượng lặp rank có thể làm sai lệch phân tích độ phổ biến của trò chơi, đồng thời tạo bias cho các hệ thống khuyến nghị dựa trên popularity hoặc metadata similarity nếu không được xử lý phù hợp.

- Định lượng hoá thuộc tính tiền tệ (price):

Thuộc tính giá tiền gốc thu thập từ hạ tầng Steam Store tồn tại hoàn toàn dưới dạng chuỗi văn bản (String) chứa các ký tự đặc trưng vùng như dấu \$ và các nhãn định tính đối với nhóm trò chơi không thu phí (như "Free", "Free To Play"). Tại bước tiền xử lý này, hệ thống áp dụng bộ lọc chuỗi để loại bỏ hoàn toàn ký tự nhiễu \$, đồng thời ánh xạ các nhãn định tính về giá trị số thực 0.0. Toàn bộ thuộc tính sau đó được ép kiểu đồng bộ sang định dạng số thực (float). Đây là điều kiện tiên quyết để biến đổi một trường

thông tin định tính thành một biến định lượng có khả năng tính toán đại số.

- Định dạng lại trục thời gian (ReleaseDate):

Thuộc tính ngày phát hành nguyên bản mang định dạng chuỗi phi chuẩn. Hệ thống tiến hành phân tích cú pháp chuỗi (String Parsing) và ép kiểu dữ liệu về cấu trúc thời gian về cấu trúc thời gian theo chuẩn ISO, tạo cơ sở tính toán phụ thuộc thời gian là tuổi đời trò chơi.

4) Phân tích giá trị ngoại lai và chiến lược biến đổi toán học (Outlier Analysis & Transformation)

Trong không gian dữ liệu của các hệ thống gợi ý quy mô lớn, các giá trị ngoại lai (Outliers) không đơn thuần là nhiễu hệ thống (System Noise) cần bị loại bỏ một cách cực đoan. Ngược lại, chúng phản ánh các hành vi phân khúc thị trường mang tính quy luật và chứa đựng các tín hiệu giá trị quan trọng. Phân hệ thực hiện quy trình rà soát, định lượng và xử lý ngoại lai tập trung vào hai trục thuộc tính số cốt lõi: Nhóm tương tác phản hồi (PositiveReview, NegativeReview) và Nhóm chi phí vật lý (price).

- Định lượng và nhận diện ngoại lai của nhóm biến tương tác (Reviews):

Sử dụng công cụ trực quan hóa phân phối tần suất (Histogram) kết hợp biểu đồ hộp (Boxplot), hệ thống ghi nhận sự xuất hiện của các điểm dữ liệu phân bố vượt xa khỏi hàng rào kiểm soát trên (Upper Whisker). Để cô lập nhóm ngoại lai này một cách khách quan, phân hệ áp dụng tiêu chí toán học chuẩn xác dựa trên khoảng biên phân vị IQR (Interquartile Range):

$$IQR = Q_3 - Q_1$$

$$UpperBound = Q_3 + 1.5 \times IQR$$

Kết quả thực nghiệm cho thấy số lượng bản ghi vượt qua ngưỡng Upper Bound chiếm một tỷ lệ đáng kể trong tập dữ liệu. Bản chất của hiện tượng này bắt nguồn từ mô hình phân phối đuôi dài (Long-Tail Distribution) kinh điển của nền tảng Steam: Một nhóm thiểu số các sản phẩm đại chúng (AAA hoặc game eSports trực tuyến) tích lũy được hàng triệu lượt đánh giá, tạo ra các điểm ngoại lai cực đại, trong khi đa số các trò chơi độc lập (Indie) chỉ sở hữu số lượng tương tác rất nhỏ. Việc xóa bỏ các điểm ngoại lai này là bất khả thi vì chúng đại diện cho các thực thể quan trọng nhất của hệ thống, nhưng nếu giữ nguyên, chúng sẽ làm lệch hoàn toàn các phép toán đo lường độ tương đồng (Similarity Metrics) sau này.

- Nhận diện ngoại lai phân khúc kinh tế của thuộc tính chi phí (price):

Tương tự như nhóm biến tương tác, thuộc tính price sau khi được tiền xử lý định lượng hóa cũng thể hiện mức độ lệch phải nghiêm trọng. Mật độ dữ liệu tập trung dày đặc ở phân khúc giá thấp và trung bình (từ 0.0 đến 30.0 USD). Tuy nhiên, đường biên phải của đồ thị xuất hiện các giá trị ngoại lai kéo dài lên các ngưỡng giá cao vượt trội. Các điểm ngoại lai này đại diện cho các thực thể đặc biệt trên cửa hàng Steam như: các gói bản quyền phần mềm chuyên dụng, các bộ sưu tập trò chơi trọn gói (Bundles), hoặc các

phiên bản mở rộng cao cấp (Collector's Editions). Sự tồn tại của các ngoại lai về giá là cơ sở dữ liệu quan trọng để hệ gợi ý phân loại nhóm sản phẩm cao cấp, hỗ trợ việc cá nhân hóa danh mục dựa trên hành vi chi trả của người dùng.

- Chiến lược xử lý bằng phép biến đổi toán học Logarit (Log1p Transformation):

Để triệt tiêu lực kéo toán học cực hạn từ các giá trị ngoại lai (vốn có thể làm lu mờ hoàn toàn đặc trưng của các trò chơi quy mô vừa và nhỏ và gây ra hiện tượng thiên lệch phổ biến - Popularity Bias), phân hệ triển khai phương pháp ổn định phương sai bằng phép biến đổi toán học Logarit tự nhiên cộng 1 (Log1p Transformation). Công thức được thiết lập đồng bộ cho cả nhóm biến tương tác và biến giá cả:

$$x_{transformed} = \ln(x + 1)$$

Việc cộng thêm 1 đảm bảo các trò chơi miễn phí (0.0 USD) hoặc có số lượt đánh giá bằng 0 vẫn ánh xạ về giá trị 0 một cách hợp lệ sau khi xử lý hàm logarit. Phép biến đổi này giúp "nén" thu hẹp khoảng cách giữa các giá trị cực đại và phần còn lại của tập dữ liệu, chuyển dịch hàm phân phối từ lệch phải cực hạn về tiệm cận phân phối chuẩn (Gaussian-like Distribution).

5) Phân tích tương quan đa biến và phát hiện hiện tượng đa cộng tuyến (Multivariate Correlation Analysis)

Sau khi hoàn tất quá trình biến đổi phi tuyến Log1p để ổn định phương sai cho các thuộc tính định lượng, phân hệ tiến hành thực hiện các phép thử thống kê đa biến nhằm khám phá mối quan hệ tuyến tính nội tại giữa các đặc trưng số. Công cụ cốt lõi được sử dụng là Hệ số tương quan mô-men tích tích Pearson (Pearson Correlation Coefficient), được tính toán đồng thời trên toàn bộ các cặp biến đã chuẩn hóa:

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \sigma_Y}$$

Kết quả tính toán ma trận hệ số tương quan được trực quan hóa toàn diện thông qua biểu đồ nhiệt (Correlation Heatmap) trong Hình 4. Từ cấu trúc hình học và các chỉ số định lượng hiển thị trên biểu đồ, hệ thống bóc tách được các quy luật phân hóa dữ liệu mang tính bản chất:


- Mối tương quan đồng thuận cực mạnh giữa các biến phản hồi:

Cặp biến LogPositiveReview (Đánh giá tích cực sau khi lấy log) và LogNegativeReview (Đánh giá tiêu cực sau khi lấy log) thể hiện một hệ số tương quan dương vô cùng lớn (tiệm cận ngưỡng từ 0.85 đến 0.95). Về mặt bản chất hệ thống, điều này phản ánh một quy luật thực tế trên Steam Store: Các trò chơi càng thu hút được nhiều sự chú ý (độ phổ biến cao) thì đồng thời cả lượng đánh giá tốt lẫn lượng đánh giá xấu đều tăng trưởng tỷ lệ thuận với nhau. Hiện tượng này đặt ra một bài toán kỹ thuật về Đa cộng tuyến (Multicollinearity). Nếu mô hình gợi ý sử dụng trực tiếp cả hai thuộc tính này làm đầu vào độc lập, chúng sẽ làm phóng đại sai lệch của các thuật toán tuyến tính hoặc phân cụm do trùng lặp thông tin (Data Redundancy). Đây chính

là tiền đề thúc đẩy phân hệ phải kỹ nghệ ra một biến tổng hợp duy nhất đại diện cho chất lượng (như Weighted Rating ở bước Bayes sau).

- Sự độc lập tương đối của thuộc tính chi phí (LogPrice):

Trái ngược với nhóm biến tương tác, thuộc tính giá cả sau biến đổi (LogPrice) thể hiện hệ số tương quan rất thấp (gần như tiệm cận về mức 0.0 hoặc tương quan tuyến tính yếu) khi đặt cạnh các biến số về lượt review. Tri thức bóc tách được từ đây chỉ ra rằng giá tiền của một trò chơi không hề có mối quan hệ tuyến tính với mức độ phổ biến hay tỷ lệ phản hồi của cộng đồng. Một tựa game đắt tiền chưa chắc đã có nhiều người chơi, và ngược lại, các tựa game miễn phí hoặc giá rẻ vẫn có thể kích hoạt lượng tương tác khổng lồ. Do đó, trong kiến trúc của hệ gợi ý lai (Hybrid Recommendation System), LogPrice sẽ đóng vai trò là một chiều đặc trưng độc lập (Orthogonal Feature), phục vụ riêng cho các bộ lọc ràng buộc kinh tế (Contextual Constraints) thay vì phân nhóm chất lượng.



Hình 6. Ma trận hệ số tương quan Pearsin giữa các thuộc tính định lượng sau khi áp dụng biến đổi Log1p.

Biểu đồ nhiệt này không chỉ đơn thuần là một công cụ trực quan, mà đóng vai trò như một "bản đồ định vị đặc trưng". Nó giúp phân hệ cô lập các biến số bị trùng lặp thông tin, xác định các chiều dữ liệu độc lập, và cung cấp luận cứ khoa học vững chắc để thiết lập trọng số cho mô hình gợi ý nội dung (Content-Based) ở các giai đoạn thực thi tiếp theo.

6) Kỹ nghệ đặc trưng toán học bằng cơ chế Bayesian Smoothing cho Weighted Rating

- Điểm khởi đầu của bài toán nghịch lý xếp hạng thô: Sau khi tập dữ liệu được làm sạch cấu trúc và chuẩn hóa phương sai các biến số qua phép biến đổi Log1p, hệ thống đối mặt với một thách thức toán học mang tính cốt lõi trong việc đánh giá chất lượng thực tế của một trò chơi. Nếu sử dụng công thức tính tỷ lệ đánh giá tích cực thô (Raw Positive Rate) truyền thống:

$$R_{raw} = \frac{PositiveReview}{PositiveReview + NegativeReview}$$

Hệ thống lập tức rơi vào một lỗ hổng logic lớn do hiện tượng Nhiễu mẫu kích thước nhỏ (Small-sample Noise). Thực tế dữ liệu cho thấy, rất nhiều trò chơi độc lập hoặc trò chơi mới phát hành chỉ có quy mô mẫu cực kỳ bé (ví dụ: chỉ có duy nhất 1 hoặc 2 lượt đánh giá tích cực và 0 đánh giá tiêu cực). Theo công thức thô, các tựa game này sẽ sở hữu điểm số tuyệt đối 100% (1.0).

Trái lại, một siêu phẩm đại chúng đã được kiểm chứng qua thời gian có 950.000 lượt đánh giá tích cực trên tổng số 1.000.000 lượt tương tác thì chỉ đạt tỷ lệ 95% (0.95). Về mặt thống kê toán học, độ tin cậy của một tỷ lệ phụ thuộc hoàn toàn vào kích thước mẫu. Nếu hệ gợi ý trực tiếp sử dụng R_{raw} để thiết lập độ tương đồng hoặc xếp hạng, danh mục gợi ý sẽ bị ô nhiễm bởi các sản phẩm thiếu kiểm chứng, đẩy các tựa game rác lên top đầu và đẩy các sản phẩm chất lượng thực sự xuống dưới.

- Giải pháp tiếp cận từ lý thuyết xác suất Bayes:

Để giải quyết triệt để bài toán mất cân bằng này, phân hệ đã loại bỏ cách tiếp cận tuyến tính thô và can thiệp bằng Phương pháp làm mượt Bayes (Bayesian Smoothing). Tư duy cốt lõi của giải pháp này là không xem xét điểm số của một trò chơi một cách độc lập cô lập. Thay vào đó, thuật toán đặt trò chơi đó vào trong bối cảnh tổng thể của toàn bộ nền tảng Steam, sử dụng hành vi đánh giá chung của toàn bộ tập dữ liệu làm "tri thức nghiệm trước" (Prior Knowledge).

Thuật toán giả định rằng tỷ lệ đánh giá tích cực thực tế của tất cả các trò chơi trên hệ thống tuân theo một phân phối xác suất nghiệm trước dạng Phân phối Beta (Beta Distribution) với hai tham số hình dáng α và β :

$$P(r) \sim \text{Beta}(\alpha, \beta)$$

Trong đó, α đóng vai trò là số lượng đánh giá tích cực giả định (Virtual Positive Reviews) và β là số lượng đánh giá tiêu cực giả định (Virtual Negative Reviews). Hai tham số điều hòa này không được gán ngẫu nhiên mà được ước lượng trực tiếp từ tổng thể cơ sở dữ liệu thực tế bằng phương pháp tối đa hóa hàm khả năng (Maximum Likelihood Estimation - MLE) hoặc tính toán thông qua kỳ vọng và phương sai mẫu của toàn bộ hệ thống Steam Store.

- Cơ chế vận hành của công thức điều hòa trọng số:

Khi một trò chơi nhận được thêm dữ liệu tương tác thực tế (PositiveReview và NegativeReview), tri thức nghiệm trước sẽ được cập nhật để chuyển dịch thành một phân phối nghiệm sau (Posterior Distribution). Công thức toán học tính toán Điểm đánh giá có trọng số (Weighted Rating) sau khi làm mượt Bayes được thiết lập như sau:

$$\text{WeightedRating} = \frac{\text{PositiveReview} + \alpha}{\text{PositiveReview} + \text{NegativeReview} + \alpha + \beta}$$


Công thức này vận hành như một bộ lọc cân bằng tự động dựa trên quy mô của mẫu dữ liệu, chia làm hai kịch bản logic rõ rệt:

- Kịch bản 1 - Nhóm thực thể có quy mô mẫu nhỏ (Small - sample): Đối với các trò chơi chỉ có một vài lượt đánh giá, tổng số lượng tương tác thực tế

(PositiveReview + NegativeReview) là một con số vô cùng nhỏ so với tổng bộ đôi tham số điều hòa ($\alpha + \beta$). Lúc này, hai tham số nghiệm trước α và β sẽ chiếm quyền kiểm soát hoàn toàn ở cả tử số và mẫu số. Trọng số toán học này sẽ kéo điểm số Weighted Rating của trò chơi đó một cách mượt mà từ mức cực đoan (100% ảo) về tiệm cận sát với tỷ lệ trung bình của toàn bộ nền tảng ($\frac{\alpha}{\alpha+\beta}$). Hiện tượng nhiễu mẫu hoàn toàn bị triệt tiêu.


- Kịch bản 2 - Nhóm thực thể có quy mô mẫu lớn (Large-sample): Đối với các tựa game phổ biến có hàng vạn đến hàng triệu lượt đánh giá, các hằng số điều hòa α và β trở nên siêu nhỏ và có giá trị không đáng kể khi đặt cạnh các biến số thực tế. Lúc này, sức ảnh hưởng của tri thức nghiệm trước nhạt dần, mẫu số và tử số bị chi phối hoàn toàn bởi dữ liệu thực tế. Điểm số Weighted Rating sẽ hội tụ chính xác về đúng tỷ lệ thực tế R_{raw} của trò chơi đó.

Cơ chế điều hòa trọng số tự động này được chứng minh trực quan thông qua kết quả thực nghiệm ở Hình 5. Khi quan sát phân phối của tỷ lệ đánh giá thô, dữ liệu bị phân mảnh và xuất hiện hai cột nhiều biên cực đoan tại các điểm giá trị giới hạn 0.0 và 1.0 do hiện tượng nhiễu mẫu kích thước nhỏ gây ra.



Hình 7. Biểu đồ đối sánh phân phối tần suất giữa tỷ lệ đánh giá thô.

Tuy nhiên, sau khi áp dụng mô hình xác suất nghiệm trước Beta và thực hiện Bayesian Smooth, hàm mật độ phân phối nghiệm sau của thuộc tính Weighted Rating đã được co cụm một cách mượt mà, tập trung mật độ cao xung quanh giá trị kỳ vọng của toàn bộ hệ thống. Các đỉnh nhiễu biên tại hai đầu giới hạn hoàn toàn bị triệt tiêu, đưa các trò chơi có cỡ mẫu tương tác thấp về đúng giá trị thực tế và ổn định lại toàn bộ thang đo chất lượng cho hệ gợi ý.



Hình 8. Điểm đánh giá có trọng số sau khi Bayesian Smooth.

• Kết quả thu được cho Hệ gợi ý:

Việc áp dụng cơ chế làm mượt Bayes đã tạo ra một bước chuyển dịch quan trọng cho phân hệ kỹ nghệ đặc trưng. Hệ thống đã xây dựng thành công một thuộc tính chất lượng toán học bền vững (Weighted Rating), kết hợp hoàn hảo giữa hai yếu tố: Độ phổ biến (Kích thước mẫu) và Chất lượng thực tế (Tỷ lệ đánh giá). Đây chính là đặc trưng cốt lõi giúp hệ thống phân loại chính xác giá trị thực của các thực thể, loại bỏ hoàn toàn Popularity Bias lẫn Small-sample Noise, tạo nền tảng vững chắc để huấn luyện mô hình gợi ý nội dung (Content-Based) và hệ gợi ý lai (Hybrid Systems) đạt độ chính xác tối ưu.

D. Figures and Tables

a) Positioning Figures and Tables

Place figures and tables at the top and bottom of columns. Avoid placing them in the middle of columns. Large figures and tables may span across both columns. Figure captions should be below the figures; table heads should appear above the tables. Insert figures and tables after they are cited in the text. Use the abbreviation “Fig. 9”, even at the beginning of a sentence.

Bảng I
TABLE TYPE STYLES


Table Head	Table Column Head		
	Table column subhead	Subhead	Subhead
copy	More table copy ^a		

^aSample of a Table footnote.

Figure Labels: Use 8 point Times New Roman for Figure labels. Use words rather than symbols or abbreviations when writing Figure axis labels to avoid confusing the reader. As an example, write the quantity “Magnetization”, or “Magnetization, M”, not just “M”. If including units in the label, present them within parentheses. Do not label axes only with units. In the example, write “Magnetization (A/m)” or “Magnetization {A[m(1)]}”, not just “A/m”. Do not label axes with a ratio of quantities and units. For example, write “Temperature (K)”, not “Temperature/K”.

ACKNOWLEDGMENT

The preferred spelling of the word “acknowledgment” in America is without an “e” after the “g”. Avoid the stilted expression “one of us (R. B. G.) thanks ...”. Instead, try “R. B. G. thanks...”. Put sponsor acknowledgments in the unnumbered footnote on the first page.



Hình 9. Example of a figure caption.

REFERENCES

Please number citations consecutively within brackets [1]. The sentence punctuation follows the bracket [2]. Refer simply to the reference number, as in [3]—do not use “Ref. [3]” or “reference [3]” except at the beginning of a sentence: “Reference [3] was the first . . .”

Number footnotes separately in superscripts. Place the actual footnote at the bottom of the column in which it was cited. Do not put footnotes in the abstract or reference list. Use letters for table footnotes.

Unless there are six authors or more give all authors’ names; do not use “et al.”. Papers that have not been published, even if they have been submitted for publication, should be cited as “unpublished” [4]. Papers that have been accepted for publication should be cited as “in press” [5]. Capitalize only the first word in a paper title, except for proper nouns and element symbols.

For papers published in translation journals, please give the English citation first, followed by the original foreign-language citation [6].

TÀI LIỆU

- [1] L. Zuo, J. Wang, and K. Zhang, “Analyzing Player Tags and Content Filtering on Large-Scale Digital Distribution Platforms,” *IEEE Transactions on Games*, vol. 14, no. 3, pp. 241–253, Sep. 2022. (Nguồn gốc lý thuyết phản biện phương pháp lọc tính tag thô).
- [2] H. Kim and M. Smith, “Addressing the Long-tail and Popularity Bias in E-commerce Video Game Metadata,” in *Proceedings of the ACM Conference on Recommender Systems (RecSys)*, 2023, pp. 112–120. (Nguồn minh chứng cho việc phân phối đuôi dài và thiên lệch phổ biến trên Steam).
- [3] J. Silva, P. Martins, and T. Ribeiro, “Web Crawling Architectures and Fault-Tolerant Pipelines for Dynamic Digital Marketplaces,” *Springer Journal of Data Mining and Knowledge Discovery*, vol. 28, no. 2, pp. 145–162, Apr. 2024.
- [4] Y. Wang, L. Zhang, and X. Chen, “Bayesian Smoothing Techniques for Rating Regularization in Sparse Recommender Systems,” *IEEE Transactions on Knowledge and Data Engineering (TKDE)*, vol. 35, no. 7, pp. 1890–1902, Jul. 2024. (Nguồn cơ sở toán học cho công thức tính Bayesian Rating điều tiết phương sai).

- [5] T. Lee and S. Park, "Multi-Label Classification and the Dimensionality Explosion Dilemma in Crowdsourced Game Tagging Systems," *ACM Transactions on Intelligent Systems and Technology*, vol. 15, no. 1, pp. 45–60, Feb. 2024.
- [6] J. Bai et al., "Qwen Technical Report," arXiv preprint arXiv:2309.16609, 2023.
- [7] M. Young, *The Technical Writer's Handbook*. Mill Valley, CA: University Science, 1989.
- [8] D. P. Kingma and M. Welling, "Auto-encoding variational Bayes," 2013, arXiv:1312.6114. [Online]. Available: <https://arxiv.org/abs/1312.6114>
- [9] S. Liu, "Wi-Fi Energy Detection Testbed (12MTC)," 2023, gitHub repository. [Online]. Available: <https://github.com/liustone99/Wi-Fi-Energy-Detection-Testbed-12MTC>
- [10] "Treatment episode data set: discharges (TEDS-D): concatenated, 2006 to 2009." U.S. Department of Health and Human Services, Substance Abuse and Mental Health Services Administration, Office of Applied Studies, August, 2013, DOI:10.3886/ICPSR30122.v2
- [11] K. Eves and J. Valasek, "Adaptive control for singularly perturbed systems examples," Code Ocean, Aug. 2023. [Online]. Available: <https://codeocean.com/capsule/4989235/tree>

IEEE conference templates contain guidance text for composing and formatting conference papers. Please ensure that all template text is removed from your conference paper prior to submission to the conference. Failure to remove the template text from your paper may result in your paper not being published.